

Projekt zaliczeniowy

Proces ETL

Grupa projektowa: Projekt24, WZISN2-1112

Imię	Nazwisko	Numer albumu	Grupa dziekańska	Wkład w prace nad projektem ¹	Udział procentowy
Mikołaj	Męderski	217067	WZISN2-1112	Stworzenie API, pobieranie danych z OTODOM, transformacja wyżej wymienionych danych, oczyszczanie dysku po całym procesie, eksport danych do ".csv" i ".txt", praca przy dokumentacji i instrukcji użycia.	33%
Krzysztof	Kowalik	216939	WZISN2-1112	Integracja z API po stronie frontendu, wyświetlanie danych w przeglądarce, praca przy dokumentacji i instrukcji użycia.	33%
Tomasz	Nowakowski	216907	WZISN2-1112	praca przy dokumentacji i instrukcji użycia.	33%

¹ proszę wymienić konkretne zadania

/70 pkt

Dokumentacja

Celem projektu jest zaprojektowanie i stworzenie aplikacji pobierającej, konwertującej i zapisującej dane pobrane z wskazanej strony internetowej. Docelową stroną internetową, z której scraper pobierze dane jest otoDom (<https://www.otodom.pl/>).

Ogólne informacje:

Aplikacja ma za zadanie pobrać dane, przekonwertować je do czytelnego dla niej formatu i zapisać je w zdefiniowanej wcześniej bazie danych. Proces powinien być automatyczny, podzielony odpowiednio na 3 fazy. Faza pierwsza to pobranie interesujących użytkownika danych, w fazie drugiej dane pobrane w fazie pierwszej poddawane są obróbce i sprowadzane do stanu pozwalającego zapisać je do bazy danych, faza trzecia to eliminacja powtarzających się danych oraz ich zapis do bazy danych. Aplikacja powinna generować raporty przy każdej fazie i zależności od preferencji użytkownika powinna wykonać cały cykl pracy i wygenerować końcowy raport, lub wykonywać następujące po sobie fazy tylko po uprzednim zatwierdzeniu ich przez użytkownika oraz generować raport przy końcu każdej fazy.

Wymagania funkcjonalne:

Opis ogólny

Aplikacja powinna składać się z trzech modułów opisanych szczegółowo poniżej. Pierwszy moduł wybiera stronę internetową, z której to pobierze dane i przygotowuje je do następnego kroku. Wygeneruje on też raport ile danych udało mu się pobrać. Drugi moduł podda pobrane dane obróbce w celu konwersji ich do docelowego formatu, dzięki któremu możliwe będzie wprowadzenie danych do bazy danych. Moduł wygeneruje również raport ile danych uległo konwersji. Trzeci moduł usunie powtarzające się dane i zapisze pozostałe dane w bazie danych oraz wygeneruje końcowy raport oraz zestawienie wszystkich trzech raportów.

Użyte technologie

Aplikacja została podzielona na trzy części technologiczne. Pierwsza z nich odpowiada za interfejs użytkownika, napisana jest przy użyciu technologii frontend'owych (JavaScript, HTML5, CSS3). Druga jest częścią wykonawczą. Jest to API napisane przy użyciu języka C#. Odpowiada za pobieranie danych ze strony OTODOM, transformuje dane na docelowy format, oraz komunikuje się z bazą danych. Ostatnia - trzecia to sama baza danych.

TECHNOLOGIE UŻYTE NA FRONCIE

Aplikacja po stronie frontend'u została stworzona w JavaScript, HTML5 oraz CSS3. W celu optymalizacji oparta jest na bibliotece ReactJS w wersji 16.12.0. W celu budowania aplikacji w wersji produkcyjnej oraz developerskiej używamy WebPack 4.41.0 pozwalający tworzyć paczki JavaScript złożone z reużywalnych i łatwo zarządzalnych modułów, możliwych do odczytania przez przeglądarkę dopiero po ich skompilowaniu w jeden plik. Kolejną technologią używa w projekcie jest Babel 7.6.0 pozwalający pisać kod używając najnowszych feature'ów dodanych między innymi

w specyfikacji ES6 oraz nowszych. Kod jest kompilowany do standardów możliwych do odczytania nawet przez starsze przeglądarki. Do wykonania interfejsu użytkownika używamy Material-ui jednej z najpopularniejszych bibliotek UI dedykowanych dla ReactJS. Dodatkowo biblioteka material-ui pozwala na użycie material-table, która zapewnia obsługę wyświetlania tabel w przyjazny dla użytkownika sposób.

TECHNOLOGIE UŻYTE W API

Aplikacja została napisana w języku C# 6.0 i używa .NET Framework w wersji 4.6.1. Główną technologią odpowiadającą za komunikację między interfejsem użytkownika, a API jest ASP.NET Web API w wersji 2.0. Jest to technologia, która używa protokołu http, a dane wysyłane są w formacie JSON. W celu wykonywania operacji scrappingu, użyta została paczka Html Agility Pack (HAP) w wersji 1.11.17. Pomaga ona wyciągać potrzebne dane z dokumentu HTML zawierającego kod strony OTODOM. Po udanej transformacji danych, są one zapisywane do pliku .json, w tym celu użyta została paczka Newtonsoft.Json w wersji 12.0.3. Pomaga ona serializować, oraz deserializować obiekty języka C#. Ostatnią technologią użytą w tej części aplikacji jest paczka CsvHelper w wersji 12.2.2, która pozwala eksportować obiekty języka C# do plików .csv.

TECHNOLOGIE UŻYTE W BAZIE DANYCH

Instalacja aplikacji

FRONTEND

W celu zainstalowania części front-end'owej należy:

- Zainstalować NodeJs z podanego linku w najnowszej wersji rekomendowanej na oficjalnej stronie:

<https://nodejs.org/en/>

- Posiadać dowolny edytor tekstu - rekomendowany Visual Studio Code, który można pobrać z oficjalnej strony:

<https://code.visualstudio.com/>

- Korzystając z wiersza poleceń przechodzimy do katalogu:

`~\WebScrapper\webscraper-frontend`

- Z wiersza poleceń uruchamiamy komendę

`npm install`

Po zakończeniu procesu instalacji wszystkie niezbędne do uruchomienia pakiety zostaną zainstalowane lokalnie na komputerze.

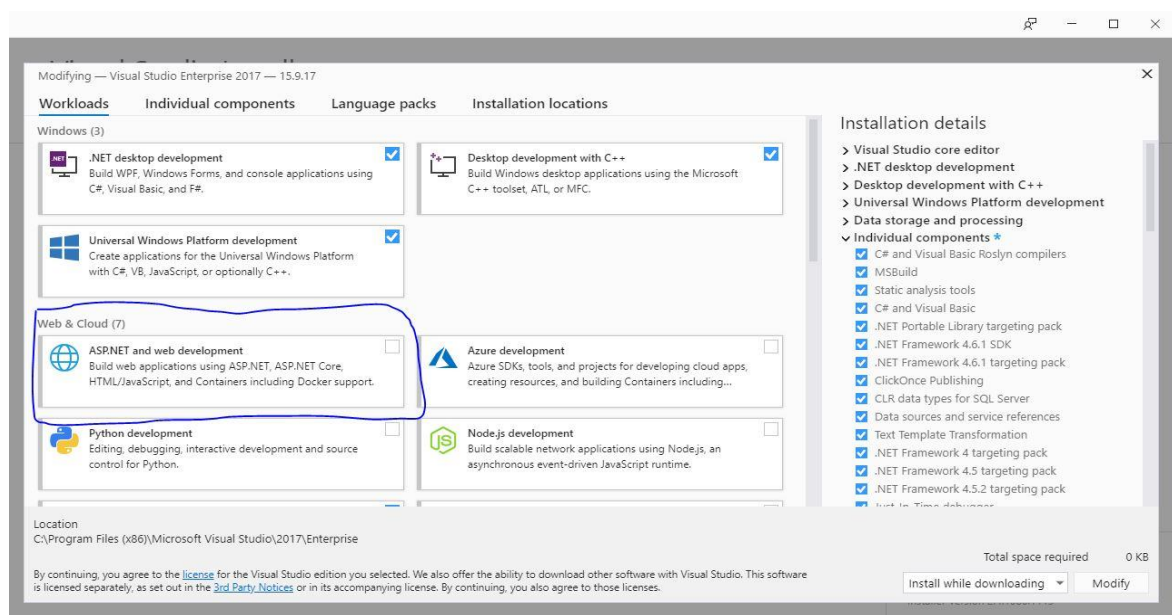
BACKEND

W celu zainstalowania API obsługującego front-end aplikacji należy:

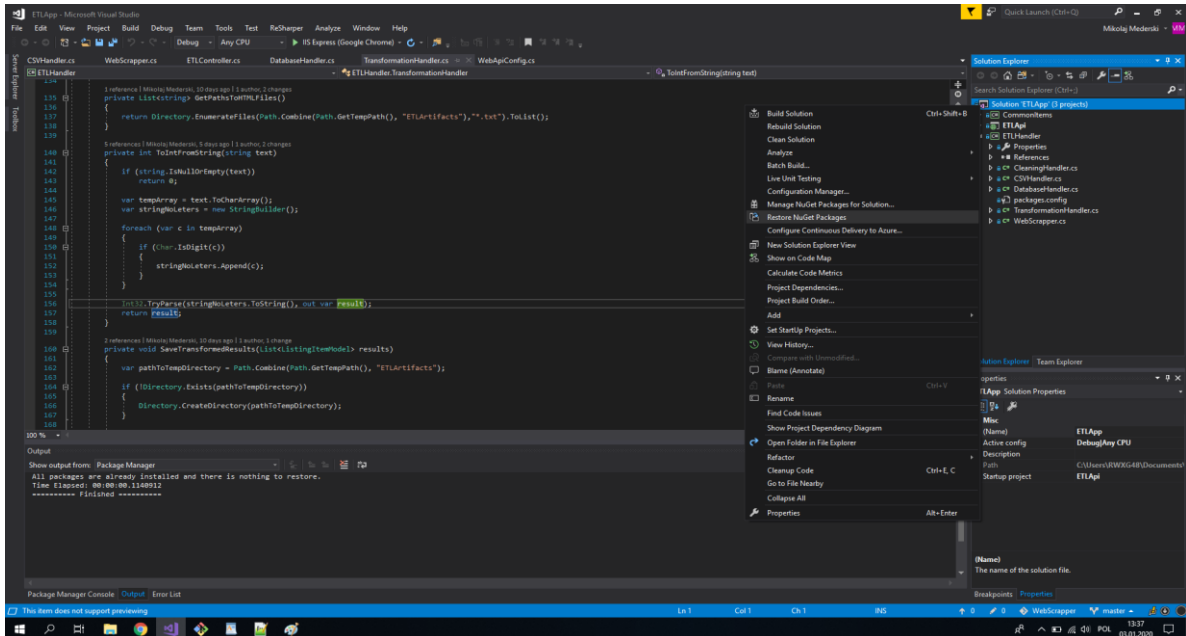
- Pobrać installer Visual Studio wchodząc w link:

<https://visualstudio.microsoft.com/pl/downloads/>

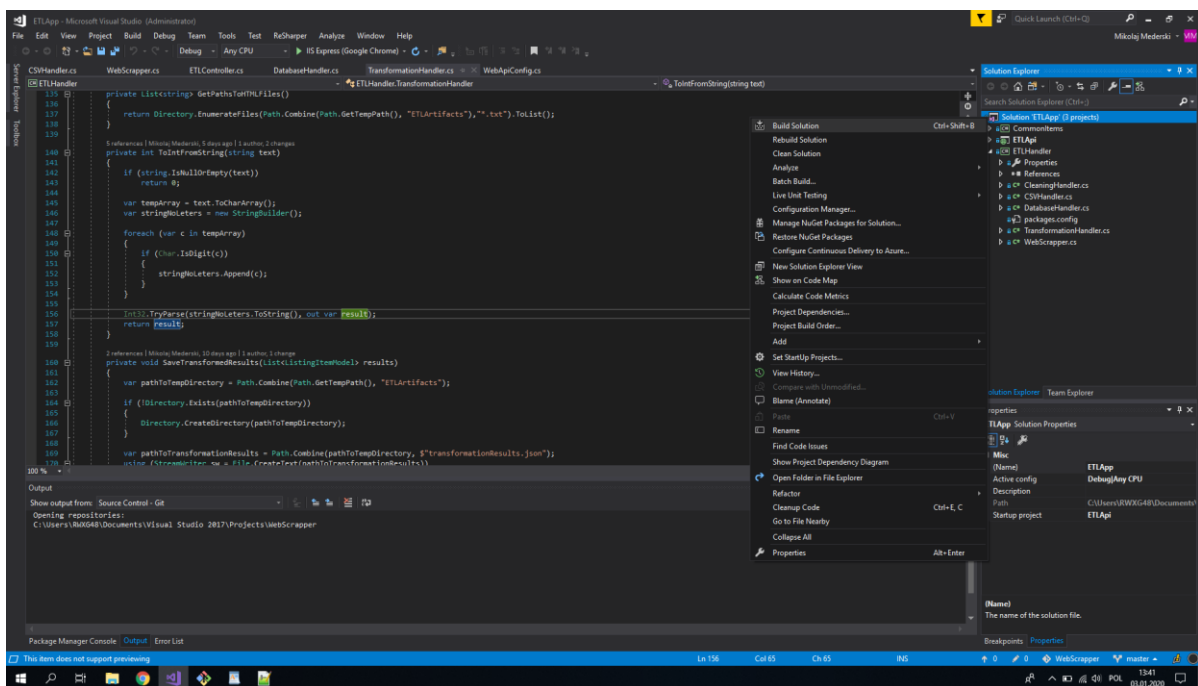
- Zainstalować Visual Studio 2017 wybierając dodatkowo ASP.NET and Web Development w zakładce Workload



- Otworzyć plik "ETLApp.sln" w programie Visual Studio 2017 wybierając kolejno w lewym górnym rogu ekranu File -> Open -> Project/Solution
- W oknie "Solution Explorer" kliknąć prawym przyciskiem myszy "Solution 'ELTApp'" i wybrać z menu opcję "Restore NuGet Packages"



- Ponownie kliknąć prawym przyciskiem myszy "Solution 'ELTApp'" i wybrać opcję Build Solution



BAZA DANYCH

Dokładny opis modułów

Moduł pierwszy - jest on odpowiedzialny za scrappowanie. Aktywowany jest po wysłaniu prośby przez interfejs użytkownika. Aby moduł mógł zadziałać poprawnie, wymagane jest podanie poprawnego adresu URL strony OTODOM, zawierającej wyniki wyszukiwania. Adres ten zapisywany jest jako pole w klasie scrappującej. Następnym krokiem jest wysłanie prośby do serwisu OTODOM, o kod źródłowy strony, do której prowadzi wcześniej wspomniany link URL. Po otrzymaniu odpowiedzi, kod ten przekazywany jest do modułu drugiego (opisanego niżej w tym dokumencie), w celu uzyskania linków URL do pojedynczych ofert, znajdujących się na stronie wyszukiwarki ogłoszeń. Po otrzymaniu listy linków, klasa scrappująca wysyła prośby o kody źródłowe konkretnych ogłoszeń. Prób tych wysłanych jest tyle, ile ogłoszeń znajdowało się na stronie wyszukiwarki. Ostatnią funkcjonalnością tego modułu jest zapisanie otrzymanych wyników do plików tekstowych, znajdujących się w folderze C:\Users\USER\AppData\Local\Temp (gdzie USER to nazwa użytkownika komputera). Zapis ten odbywa się jedynie wtedy gdy użytkownik wybierze funkcję Extract. Podczas funkcji ETL nie zachodzi potrzeba zapisywania danych do zewnętrznych plików. Dane zapisane w plikach tekstowych mogą następnie zostać odczytane przez moduł drugi, podczas transformacji.

Moduł drugi - odpowiedzialny za transformacje. Posiada on dwie główne funkcjonalności:

- Transformacje danych na format, który pozwala na zapis do bazy danych
- Wyciąganie adresów URL poszczególnych ogłoszeń zawartych na stronie wyszukiwarki serwisu OTODOM.

Pierwsza funkcjonalność działa na dwa sposoby, w zależności od ścieżki którą wybrał użytkownik. Jeśli wybrana została ścieżka pojedynczych kroków (osobno Extract, osobno Transform i osobno Load) wtedy dane potrzebne do transformacji (kod HTML ogłoszeń) odczytywany jest z plików powstałych podczas działania modułu pierwszego. Jeśli wybrana została ścieżka automatyczna (wszystkie kroki ETL wykonywane są jeden po drugim, bez ingerencji użytkownika) dane do transformacji przekazywane są bezpośrednio z poprzedniego modułu.

Gdy moduł ma już dostęp do danych, kod źródłowy ogłoszeń jest odczytywany przez Html Agility Pack, a następnie wyciągane są z niego części kodu odpowiedzialne za część tytułową ogłoszenia, oraz część posiadającą dane szczegółowe (np. rodzaj ogrzewania, rok budowy budynku). Te dwie sekcje są następnie przekazywane do funkcji odpowiedzialnej za wyciągnięcie konkretnych wartości liczbowych, bądź informacji tekstowych i stworzenie obiektu C#, posiadającego interesujące nas pola.

Kończąc swe działanie, na podstawie ścieżki wybranej przez użytkownika moduł zapisuje dane po transformacji, jeśli użytkownik wybrał ścieżkę pojedynczych kroków. Dane zapisywane są w pliku o formacie „json”.

Druga funkcjonalność wykorzystywana jest przez moduł pierwszy. Funkcja otrzymuje kod źródłowy strony, na której wylistowane są ogłoszenia. Następnie tworzy listę pojedynczych ogłoszeń i z każdego ogłoszenia wyciąga jego adres URL. Lista adresów zwracana jest do modułu pierwszego.

Moduł trzeci - odpowiedzialny za komunikację z bazą danych.

Moduł pomocniczy - wykonuje on operacje nie związane z procesem ETL. Zawiera on

- Eksport danych do pliku o formacie „csv”
- Eksport pojedynczego ogłoszenia do pliku o formacie „txt”
- Usuwanie plików powstałych podczas procesu ETL.

Tabele klas i atrybutów

Backend

ListingItemModel

Atrybuty:

Nazwa	Typ	Opis
Title	string	Pole przechowujące tytuł ogłoszenia
Rooms	int	Pole przechowujące ilość pokoi w nieruchomości
Area	string	Pole przechowujące powierzchnie nieruchomości
Price	string	Pole przechowujące cenę nieruchomości
Bond	int	Pole przechowujące kaucję za nieruchomość
BuildingType	string	Pole przechowujące rodzaj nieruchomości (np. Blok)
Windows	string	Pole przechowujące typ okien w nieruchomości (np. plastikowe)
BuiltIn	int	Pole przechowujące rok budowy nieruchomości
HeatingType	string	Pole przechowujące rodzaj ogrzewania (np. miejskie)
Materials	string	Pole przechowujące rodzaj materiałów budulcowych
Floor	int	Pole przechowujące piętro na którym znajduje się nieruchomość
Address	string	Pole przechowujące lokalizację nieruchomości
FloorsInBuilding	int	Pole przechowujące ilość pięter w budynku

CLEANINGHANDLER

Funkcje Składowe:

Nazwa	Wartość Zwracana	Parametry	Opis
DeleteArtifacts	Void	Brak	Funkcja usuwająca pliki powstałe podczas procesu ETL

CSVHANDLER

Funkcje Składowe:

Nazwa	Wartość Zwracana	Parametry	Opis
ExportToCSV	Void	List<ListingItemModel> - Lista ofert	Tworzy plik ".csv" z danymi, które zostały przekazane w parametrze
ExportSingleToTxt	Void	ListingItemModel - pojedyncza oferta	Tworzy plik ".txt" z danymi oferty przekazanej w parametrze
ValidateOfferTitle	string	string title	Zamienia znaki typu "," na znak "_", w celu stworzenia nazwy pliku na podstawie tytułu oferty
GetPathToFile	string	string fileName	Zwraca ścieżkę, w której powstanie plik z wyeksportowanymi danymi

DATABASEHANDLER

Funkcje składowe:

Nazwa	Wartość Zwracana	Parametry	Opis

TRANSFORMATIONHANDLER

Atrybuty:

Nazwa	Typ	Opis
_polishChars	static readonly char[]	przechowuje wszystkie polskie znaki
_englishChars	static readonly char[]	przechowuje angielskie odpowiedniki polskich znaków

Funkcje składowe:

Nazwa	Wartość Zwracana	Parametry	Opis
GetListOfProducts	List<ListingItemModel>	bool needSave, List<string> rawHtmlList	Zwraca listę ofert pod postacią obiektów

			ListingItemModel
GetAdsUrls	List<string>	string rawHtml	Zwraca wszystkie URLe ogłoszeń zawartych w HTMLu przekazany w parametrze
GetOfferDetails	ListingItemModel	HtmlNode details HtmlNode title	Tworzy obiekt ListingItemModel przypisując wartości pól na podstawie sekcji HTML przekazanych w parametrze
GetPathsToHTMLFiles	List<string>	Brak	Zwraca lokalizacje plików zawierających kod HTML ofert
ToIntFromString	int	string text	Przerabia string w którym znajdują się cyfry na int ignorując litery. Np "30 zł" -> "30"
SaveTransformedResults	Void	List<ListingItemModel> results	Tworzy plik formatu ".json" zawierający listę ofert w postaci ListingItemModel
RemoveDiacritics	string	string text	Zamienia wszystkie polskie znaki na ich angielskie odpowiedniki

WEBSCRAPPER

Atrybuty:

Nazwa	Typ	Opis
_url	readonly string	Zawiera adres witryny OTODOM
_httpClient	HttpClient	Instancja klasy HttpClient, wykorzystywana do komunikacji internetowej
_transformer	TransformationHandler	Instancja klasy TransformationHandler

		opisanej powyżej
--	--	------------------

Funkcje składowe:

Nazwa	Wartość Zwracana	Parametry	Opis
KONSTRUKTOR: WebScraper	Brak	String url	Przypisuje wartosc pola _url, oraz tworzy nowe instancje HttpClient i TransformationHandler
GetRawHtmls	List<string>	bool needSave	Pobiera kod źródłowy znajdujący się pod adresem z pola _url, a następnie pobiera kod źródłowy pojedynczych ofert
SaveRawHtmlToText	Void	string result int documentNumber	Tworzy plik o nazwie "rawHtmlX.txt" gdzie X to liczba ze zmiennej documentNumber. Zawartością pliku jest ciąg literalny result

ETLCONTROLLER

Funkcje składowe:

Nazwa	Wartość Zwracana	Parametry	Opis
Get	IHttpRequestResult	JsonBodyModel model	Wywołuje akcje Extract
Transform	IHttpRequestResult	Brak	Wywołuje akcje Transform
Load	IHttpRequestResult	Brak	Wywołuje akcje Load
FullETL	IHttpRequestResult	JsonBodyModel model	Wywołuje po kolei akcje Extract, Transform, Load
ExportToCSV	IHttpRequestResult	List<ListingItemModel> offers	Wywołuje eksport do ".csv" danych przekazanych w parametrze offers
CleanDb	IHttpRequestResult	Brak	Wywołuje czyszczenie bazy danych
ExportSingleToTxt	IHttpRequestResult	ListingItemModel offer	Wywołuje eksport do ".txt" oferty przekazanej w parametrze offers
GetAllRecords	IHttpRequestResult	Brak	Wywołuje metodę wyciągającą całą zawartość bazy

			danych
--	--	--	--------

JSONBODYMODEL

Atrybuty:

Nazwa	Typ	Opis
url_adress	string	Adres witryny OTODOM

Frontend

Funkcje składowe:

Nazwa	Wartość Zwracana	Parametry	Opis
handleSubmit	IHttpRequest	Submit Event	Wysyłanie formularza z podanym adresem url, zapobieżenie domyślnej akcji przeglądarki po wysłaniu formularza.
postUrl	function	String url	Wysyła adres url do API w celu uruchomienia procesu Extract.
getAfterTransform	IHttpRequest	Brak	Uruchomienie metody odpowiedzialnej za pobieranie danych z domeny otodom.
fetchData	IHttpRequest	Brak	Uruchomienie procesu Transform, wyświetlenie statusu zapytania po wysłaniu zapytania.
getAfterLoad	IHttpRequest	Brak	Uruchomienie metody Load zwracającej dane otrzymane po scrapowaniu i wyświetlenie ich w przeglądarce.
fullETLProcess	IHttpRequest	Brak	Uruchomienie metod odpowiedzialnych za Export, Transform, Load automatycznie jedna po drugiej jeśli poprzednia zakończyła się sukcesem i

			wyświetlenie rezultatów.
exportToCsv	IHttpRequest	Brak	Export tabeli do pliku .csv.
exportSingleElement	IHttpRequest	rowData	Export pojedynczego wiersza z tabeli do pliku .txt.
cleadDb	IHttpRequest	Brak	Czyszczenie bazy danych

Baza danych

Instrukcja obsługi aplikacji:

Instrukcja uruchomienia aplikacji:

Uruchomienie części front-end'owej:

Aby uruchomić wersie deweloperską aplikacji front-end'owej najlepiej skorzystać z wiersza poleceń (domyślny dostępny w systemie operacyjnym Windows). Powinniśmy znajdować się w katalogu aplikacji front-end'owej:

```
~\WebScraper\webscraper-frontend
```

Z tego miejsca uruchamiamy polecenie:

```
npm start
```


Powyższa komenda automatycznie otworzy domyślną przeglądarkę i uruchomi aplikację pod portem:

<http://localhost:3000/>


Uruchomienie części back-end'owej:

Aby uruchomić API obsługujące front-end aplikacji należy:


- Uruchomić program Visual Studio 2017
- Otworzyć plik "ETLApp.sln" w programie Visual Studio 2017 wybierając kolejno w lewym górnym rogu ekranu File -> Open -> Project/Solution
- W menu podświetlonym na zdjęciu poniżej wybrać opcje IIS Express



- Kliknąć w przycisk Startu



Po kliknięciu w przycisk Start, otworzy się nowe okno przeglądarki. Komunikat „**403 Forbidden**” wskazuje, na poprawne działanie serwisu.



Uruchomienie bazy danych

Opis funkcjonalności aplikacji:

Aplikacja ma na celu pobranie danych ze źródła (otodom.pl), odpowiedniego ich przekształcenia i zasilenia nimi bazy danych. Są to składowe procesy ETL, który główną funkcjonalnością naszej aplikacji. Ponadto istnieje możliwość eksportu danych do pliku .csv lub .txt. Dane wyświetlane w tabeli możemy filtrować, sortować w sposób umożliwiający użytkownikowi jak najlepsze ich przetwarzanie.

Opis scenariuszy użycia aplikacji:

Aplikacja posiada dwa scenariusze użycia:

- W pierwszym musimy uruchomić wszystkie etapy manualnie pamiętając, że do uruchomienia kolejnego konieczne jest pozytywne zakończenie etapu poprzedniego.
- W drugim scenariuszu cały proces wykonywany jest automatycznie przy użyciu przycisku „*ETL*”.

Opis menu i widoków okna aplikacji:

WebScrapper

Type URL adress from Otodom.pl

URL adress *

EXTRACT TRANSFORM LOAD **ETL** EXPORT TO .CSV

Extract detail:

Please type URL adress

Transform detail:

Data:

Aplikacja podzielona została na kilka sekcji:

Menu funkcyjne:

- Pole typu input – pozwalające wprowadzić adres URL strony, którą użytkownik będzie Scrapował wraz z walidacją wymagającą wpisania poprawnego adresu ze strony otodom.pl

URL adress *

URL adress *

Wypełnij to pole.

URL adress *

test

Url have to be from otodom.pl

- Przycisku funkcyjne odpowiedzialne za uruchamianie kolejnych etapów procesu ETL osobno - *'EXTRACT'*, *'TRANSFORM'*, *'LOAD'*, przycisk *'ETL'* wykonujący cały proces automatycznie oraz *'EXPORT TO .CSV'* generujący plik z wszystkimi danymi znajdującymi się w tabeli w formacie .csv. W początkowej fazie działania aplikacji nie ma możliwości użycia przycisków wyszarzonych, ponieważ wymagają one ukończenia poprzedniego etapu procesu.



- Przycisk odpowiedzialny za czyszczenie bazy danych



Informacje o postępie i efektach procesu

- *EXTRACT* – sekcja mówiąca o postępie etapu *EXTRACT*. Informuje nas czy etap zakończył się sukcesem lub czy podany adres URL jest błędny, ponieważ nie zawiera żadnych ogłoszeń możliwych do pobrania (np. strona startowa domeny otodom.pl).

Extract detail:

Please type URL adress

Extract detail:

Invalid URL adress - please type correct adress

Extract detail:

Success - Data extracted !!!

Po pozywonym zakończeniu etapu *EXTRACT* przycisk *TRANSFORM* staje się aktywny i możemy przejść do kolejnego procesu.



- *TRANSFORM* – informuje nasz ile ofert zostało pobranych i pozywianie przeszło etap *TRANSFORM* po czym aktywuje kolejny etap *LOAD*:






Transform detail:

Transformed 26 Results



- **DATA** – sekcja w której załadowane zostają pobrane dane w formie tabeli. Tabela posiada sortowanie, wyszukiwarke, możliwość przesuwania i decydowania o kolejności kolumn, możliwość zmiany ilości wierszy oraz w pierwszej kolumnie ‘Action’ przycisk do exportu pojedynczego wiersza i zapisania go w formacie .txt.

Data:

Adverts									
<div> <div></div> <div>Search</div> <div></div> </div>									
Actions	Title	Rooms	Area	Price	Bond	BuildingType	FloorsInBuilding	Windows	HeatingType
	Rumia ul. Jeziorna, 2 pokoje, ogródek, Orlex Invest	2	38,46 m²	215 000 zł	0	blok	3	plastikowe	gazowe
	Inwestuj w najem Okazja *** 26m2, przy Stacji SKM!	2	26 m²	215 000 zł	0	blok	0	Brak Informacji	Brak Informacji
	komfortowe m3 parter duży balkon umeblowane !	2	36,60 m²	215 000 zł	0	Brak Informacji	10	Brak Informacji	Brak Informacji
	Mieszkanie, 33,50 m², Gorzów Wielkopolski	2	33,50 m²	215 000 zł	0	Brak Informacji	2	plastikowe	miejskie
	II Piętro- Super Lokalizacja!!!	2	37,70 m²	215 000 zł	0	blok	4	plastikowe	miejskie

Po zakończeniu etapu *LOAD* możemy wyeksportować całą tabelę do pliku .csv jednocześnie wyłączmy możliwość wykonania etapu *TRANSFORM* oraz *LOAD* umożliwiając jedynie rozpoczęcie procesu na nowo i kolejne zasilenie hurtowni danych.



Podczas działania każdego procesu uruchamiany jest loader w celu zablokowania interfejsu użytkownika na czas trwania wykonywania procesu:

